

DIPLOMADO EN CIENCIA DE DATOS

PROYECTO CLARALAP

Inteligencia Artificial Aplicada al Sector de Equipos de Cómputo Portátiles



*Sistema inteligente de recomendación y auditoría financiera de hardware
con traducción empática para el público en general*

REPORTE TÉCNICO FINAL

10 de octubre de 2026

Índice

1. Introducción	2
2. Planteamiento del Problema	2
3. Descripción de los Datos	3
4. Ingeniería de Datos y Limpieza	3
4.1. Limpieza inicial y corrección de estructura de los datos	4
4.2. Inferencia de Especificaciones y Exclusión de Ruido	4
4.3. Reevaluación Fina de Hardware y duplicación	5
5. Análisis Exploratorio de Datos (EDA)	5
5.1. Análisis Univariado y Distribuciones	5
5.2. Ingeniería de Variables y Jerarquización de Componentes	9
6. Modelación Supervisada	9
6.1. Modelo de clasificación	9
6.2. Modelo de Regresión (Predicción de Precio Justo)	11
7. Estrategia de Negocio	13
7.1. Identificación de Oportunidades	14
7.2. Identificación de sobrepuestos	14
7.3. Motor de Match Matemático y Traductor Empático (LLM)	14
7.4. Conclusiones	16
7.5. Siguiendo Pasos	16

1. Introducción

El proyecto **ClaraLap** surge con el objetivo de democratizar el acceso a la tecnología adecuada, simplificando de manera radical el proceso de búsqueda, evaluación y selección de laptops para el consumidor promedio. En el mercado actual de cómputo portátil, el comprador tradicional enfrenta una asimetría de información crítica: existe un volumen abrumador de modelos con nomenclaturas complejas y fluctuaciones de precio arbitrarias entre tiendas en línea.

El propósito central de ClaraLap es actuar como un **asesor tecnológico personal** a través de una plataforma web intuitiva. La herramienta guía a los usuarios —independientemente de sus conocimientos técnicos— hacia el portátil ideal que satisfaga sus necesidades particulares y se ajuste a su presupuesto disponible en cuestión de segundos, ahorrándole tiempo de búsqueda, caer en ofertas engañosas o la búsqueda de asesoría de terceros.

Mediante la integración de Web Scraping a tiendas online, el aprendizaje automático (modelo regresión) y Procesamiento de Lenguaje Natural (LLMs), el sistema reemplaza la jerga incomprensible y técnica por un diálogo empático basado en tareas reales que puede tener el usuario (“Diseño gráfico”, “Programación”, “Oficina” o “Gaming”, por ejemplo).

2. Planteamiento del Problema

El proceso de compra de un equipo de cómputo portátil se encuentra obstaculizado por tres factores principales:

1. **La Barrera Técnica:** Los consumidores conocen sus necesidades operativas diarias (desde mirar redes sociales hasta usos específicos como el diseño gráfico o gaming), pero en ocasiones carecen del vocabulario técnico para traducir estas acciones en requerimientos de hardware (RAM, hilos de CPU, VRAM, tipo de almacenamiento, etc).
2. **Falta de Transparencia Financiera:** Los usuarios llegan a estar expuestos a practicas de las tiendas o vendedores donde suelen pagar por tener notoriedad en tiendas en linea, lo que expone al comprador a sobrepuestos por comprar ciertas marcas de ciertas tiendas y evitando que consigan equipos menos populares que pudieran ser más adecuados a sus requerimientos.
3. **Insuficiencia de los LLMs Genéricos:** Si el usuario decide consultar a una Inteligencia Artificial conversacional tradicional (como ChatGPT) se expone a las deficiencias y limitaciones de los mismos: los LLMs sufren de alucinaciones sobre disponibilidad física en inventarios locales, no auditan si el precio de una tienda es un cobro excesivo o una oferta real, y recomiendan productos basándose en predicción probabilística de texto en lugar de un ranking matemático estricto.

Ventaja Competitiva de ClaraLap

Dimensión	LLMs Genéricos (ej. ChatGPT)	Plataforma ClaraLap
Disponibilidad de Inventario	Alucina modelos discontinuados o sin stock local.	Extrae datos en vivo via Web Scraping con enlaces directos de compra.
Auditoría Financiera	No evalúa si el costo monetario es adecuado o justo.	Implementa el modelo de Regresión que calcula el Precio Justo según componentes.
Criterio de Selección	Predicción probabilística de texto.	Modelo Random Forest con Match de compatibilidad matemático.
Explicación al Usuario	Genérica o highly técnica.	Traductor empático mediante LLM orientado a beneficios prácticos.

Cuadro 1: Comparativa de características entre LLMs genéricos y ClaraLap.

3. Descripción de los Datos

Para la construcción de la base de datos de ClaraLap, se recolectó un dataset masivo de laptops en el mercado mexicano mediante scraping web. El catálogo inicial registrado contenía un total de **35,412 registros** distribuidos en 17 columnas con información técnica, precios en pesos mexicanos (MXN), tiendas distribuidoras y URLs.

Listing 1: Estructura Inicial del Dataset

```
Estructura Inicial del Dataset:
- Registros totales procesados: 35,412
- Columnas iniciales: ID_Global, Tienda, ID_Producto, Marca,
  Nombre, Precio_MXN,
  RAM_GB, Almacenamiento_GB, Tipo_Almacenamiento, Procesador,
  GPU_Dedicada,
  Pantalla_Pulgadas, Procesador_Modelo, Numero_Nucleos,
  Generacion_CPU
```

4. Ingeniería de Datos y Limpieza

El pipeline de ingeniería de datos se diseñó para transformar texto no estructurado procedente de los títulos y especificaciones de las tiendas en un **Dataset ORO** apto para algoritmos de Machine Learning.

Listing 2: Pipeline de Calidad y Limpieza de Datos

```
[Data Cruda: 35,412]
|
|-> Se homogenizaron los valores en Precio_MXN
```

```
|-> Se coloco la información correcta cuando se detecto un
    intercambio entre la memoria RAM y la memoria en disco.
|-> Eliminacion de equipos para piezas/refacciones (-1,053)
|-> Rescate Regex de los valores de almacenamiento en disco
    desde el Titulo (+24,495 recuperados)
|-> Eliminación de registros correspondientes a
    accesorios/muebles (-3,002)
|-> Correccion de VRAM/GPU asignada a disco (-90)
|-> Reevaluacion de Pantallas imputando por el tamaño más
    frecuente (3,138 corregidas)
|-> Recuerperación de información de Almacenamiento en TB a
    partir del titulo de la publicación
|-> Eliminación de duplicados (-13,565)
|
[Dataset Final con registros únicos: 2,217 laptops unicas]
```

4.1. Limpieza inicial y corrección de estructura de los datos

- **Precio_MXN:** Se eliminaron símbolos de moneda (\$), textos de divisa (MXN), comas de miles y espacios, convirtiendo la columna a formato numérico de punto flotante float64 sin generar registros nulos.
- **Intercambio RAM / Almacenamiento:** Se corrigieron incoherencias en las que la RAM resultaba mayor al almacenamiento (ej. RAM = 512, Almacenamiento = 16), invirtiendo ambos valores. Para valores idénticos en ambas variables, se asignó NaN a la columna correspondiente según los umbrales lógicos del mercado (≤ 128 GB corresponde a RAM; > 128 GB a almacenamiento).

4.2. Inferencia de Especificaciones y Exclusión de Ruido

- **Rescate de Marca de Procesador:** Mediante expresiones regulares sobre el título de la publicación, se infirió la marca del procesador para **11,247 registros** que figuraban como “No especificado”, incrementando la cobertura útil a 23,945 registros.
- **Depuración de Refacciones y Accesorios:** Se identificaron y eliminaron **1,053 publicaciones** correspondientes a equipos dañados o para piezas (palabras clave: *piezas, refacciones, reparar, desarme*). Posteriormente, se removieron **3,002 registros** pertenecientes a accesorios o muebles (*escritorios, mesas, soportes, fundas, cargadores*) y **912 registros** carentes de anclas técnicas de laptop, es decir, palabras clave que nos permitiera identificar el registro como perteneciente a una laptop.
- **Recuperación de Almacenamiento_GB:** Se extrajo la capacidad de disco desde la columna Nombre mediante patrones Regex para TB, GB y combinaciones de SSD/HDD/NVMe, logrando recuperar la información en **24,495 registros** y elevando la completitud de la variable del 10.21 % al 81.50 %.

4.3. Reevaluación Fina de Hardware y duplicación

- **Corrección de VRAM en Almacenamiento:** Se corrigieron **90 casos** donde la memoria de video dedicada de la tarjeta gráfica (ej. “RTX 4050 de 6GB”) había sido asignada erróneamente como almacenamiento principal del sistema.
- **Ajuste de Tamaños de Pantalla:** Se corrigieron **3,138 registros** donde errores de redacción en los títulos (ej. “105 pulgadas” en lugar de “10.5 pulgadas”) distorsionaban las dimensiones reales.
- **Deduplicación:** Se eliminaron **13,565 duplicados exactos** y **6 duplicados comerciales funcionales** (mismo modelo, hardware y precio publicado repetidamente), conservando **2,217 registros únicos**.

Cabe mencionar que durante este proceso fueron imputados la mayor cantidad de valores nulos que había originalmente en el dataset

5. Análisis Exploratorio de Datos (EDA)

5.1. Análisis Univariado y Distribuciones


El análisis sobre la base de datos limpia (2,217 registros) reveló las siguientes características estructurales de mercado:

Variable	Media	Mediana	Mínimo	Máximo
Precio_MXN	\$16,795.96	\$13,638.50	\$1,250.00	\$164,528.00
RAM_GB	15.49 GB	16.00 GB	1.00 GB	128.00 GB
Almacenamiento_GB	556.15 GB	512.00 GB	32.00 GB	2,048.00 GB
GPU_Dedicada (Bin)	0.11 (11 %)	0.00 (0 %)	0.00	1.00
Pantalla_Pulgadas	15.07”	15.60”	10.10”	18.00”

Cuadro 2: Resumen Estadístico de Variables Numéricas.


- **Precios:** Presentan un sesgo positivo hacia la derecha; el 66.2% de los equipos cuesta menos de \$17,577.80 MXN, existiendo una cola larga de equipos de alta gama que superan los \$100,000.00 MXN.

Distribución de la variable: Precio_MXN




- **Tecnología de Almacenamiento:** El **99.82 %** de las laptops cuenta con discos de estado sólido (SSD), mientras que solo el 0.18 % conserva discos mecánicos (HDD). Por lo que puede ser descartada al considerarse una variable unaria

Distribución de Categorías (Top 10): Tipo_Almacenamiento




- **Distribución de Marcas:** HP domina la oferta con un 57.94 %, seguida por Lenovo (13.11 %), Asus (8.35 %), Dell (5.31 %), Apple (2.77 %) y MSI (2.77 %).

Distribución de Categorías (Top 10): Marca




- **Disponibilidad de GPU:** El **89.43 %** de los equipos no cuenta con tarjeta de video dedicada, lo que convierte a la categoría *Gaming / Workstation* en un segmento minoritario.

Distribución de la variable: GPU_Dedicada




- **Distribución de Memoria RAM:** Presenta una distribución discreta y escalonada centrada en potencias de 2. Las capacidades de 8 GB y 16 GB dominan ampliamente el mercado, acumulando el 72.73

Distribución de la variable: RAM_GB




- **Procesador:** Evidencia el nivel de detalle recuperado de los títulos. A pesar de la presencia de valores "No especificados" de origen (31.58 % a 48.23 %), destacan las líneas Intel Core i5 (13.79 %), Intel N150 (9.30 %), AMD Ryzen 5 (9.12 %) e Intel Core i7 (7.26 %).

Distribución de Categorías (Top 10): Procesador



- **Distribución de Disco Duro:** Exhibe picos de frecuencia muy marcados en capacidades comerciales estándar, destacando los 512 GB (con el 36.89 % del total), 256 GB (17.29 %) y 1 TB / 1024 GB (19.42 %).

Distribución de la variable: Almacenamiento_GB



Observaciones

- El 89.43 % de los equipos no cuenta con GPU dedicada, lo que significa que la clase “Gama Alta” o “Gaming” será una clase minoritaria.
- La RAM se concentra en 8 GB y 16 GB (acumulando el 72.73 % de la muestra).
- El precio tiene un fuerte sesgo a la derecha (asimetría positiva). El 66.2 % de las laptops cuestan menos de \$17,577 MXN, pero existe una “cola” de equipos con precios atípicos que superan los \$100,000 MXN.
- Las variables de RAM_GB y Almacenamiento_GB tienen “brincos” de escala grandes.
- Más del 48 % de los procesadores tienen la categoría de “No especificado”.

Estrategias

- Para casos como este podemos usar las métricas F1-Score, Precisión y Recall para evaluar qué tan bien el modelo detecta la clase minoritaria.
- También podemos ajustar el hiperparámetro de peso de clases para penalizar más los errores en la predicción de la clase minoritaria.
- Dado que el 80.35 % de las pantallas se concentra en 14” y 15.6”, podemos convertir esta variable numérica en categórica (“Ultra-portátil < 14”, “Estándar 14–15”, “Grande > 15”).
- Para la variable del precio podríamos utilizar la transformación logarítmica para tratar de hacerla más simétrica y a la vez podemos usar el modelo de Random Forest para el modelo de regresión y así evitar afectaciones debidas al sesgo.
- Considerando que para las variables de RAM_GB y Almacenamiento_GB tenemos brincos en la escala podemos usar `MinMaxScaler` para estandarizar las escalas.
- Podemos usar una transformación logarítmica para RAM_GB y Almacenamiento_GB pues su aumento es escalonado y no continuo.
- Para ayudar al modelo a identificar la jerarquía entre los procesadores podemos generar un nuevo campo para clasificarlos. Dado que la mayoría de los procesadores tiene la categoría de “No especificado” podemos valernos del valor de la

RAM considerando que modelos con menor RAM estarían asociados a laptops con procesadores de gamas más bajas y viceversa.

5.2. Ingeniería de Variables y Jerarquización de Componentes

Para alimentar los modelos de Machine Learning, se crearon variables sintéticas de alta discriminación técnica:

1. **Transformaciones Logarítmicas Base 2:** Dado que la memoria RAM y el almacenamiento crecen en potencias de 2 (4, 8, 16, 32, 512, 1024), se aplicó $\log_2(\text{RAM_GB})$ y $\log_2(\text{Almacenamiento_GB})$ para obtener una escala lineal homogénea (ej. $\log_2(8) = 3$, $\log_2(16) = 4$, $\log_2(32) = 5$).
2. **Jerarquía Detallada de CPU (CPU_Tier_Detallado, 1 a 6):**
 - *Tier 6:* Intel Ultra 9, Core i9, Ryzen 9, Apple M2/M3/M4 Max/Pro[cite: 8].
 - *Tier 5:* Intel Ultra 7, Core i7, Ryzen 7, Apple M2/M3[cite: 8].
 - *Tier 4:* Intel Ultra 5, Core i5, Ryzen 5[cite: 8].
 - *Tier 3:* Core i3, Ryzen 3[cite: 8].
 - *Tier 1-2:* Celeron, Pentium, Athlon, N100/N200/N305[cite: 8].
3. **Jerarquía Detallada de GPU (GPU_Tier_Detallado, 0 a 6):**
 - *Tier 6:* RTX 4090 / 5090 / 3090[cite: 8].
 - *Tier 5:* RTX 4080 / 5080 / 3080 / A3000-A5000[cite: 8].
 - *Tier 4:* RTX 4070 / 5070 / 3070 / A2000[cite: 8].
 - *Tier 3:* RTX 4060 / 5060 / 3060 / A1000[cite: 8].
 - *Tier 2:* RTX 4050 / 3050 / 2050 / GTX / Radeon RX[cite: 8].
 - *Tier 1:* Gráficos integrados Iris, Radeon, UHD[cite: 8].
 - *Tier 0:* Gráficos básicos de entrada[cite: 8].
4. **Banderas Categóricas e Interacciones:** Variables booleanas para identificar *Es_Reacondicionado*, *Es_Gaming*, *Es_Workstation*, *Es_Linea_Premium*, *Es_Touch*, *Es_OLED*, *Es_Apple* y términos de interacción como *RAM × CPU* y *Gaming × GPU*[cite: 7, 8].

6. Modelación Supervisada

6.1. Modelo de clasificación

En un inicio se consideró realizar un modelo de clasificación que determinara si una laptop era de gama baja, media o alta.

Sin embargo, dicha variable se generó usando reglas deterministas y al implementar un clasificador de random forest se presentó overfitting de tal modo que el clasificador llegó al 100 % de aciertos tanto en train como en test. Por lo que se determinó que el modelo aprendió la regla determinista con la que se generó la variable objetivo.

En tal caso, clasificación por medio de un modelo fué descartada para reemplazarla por un algoritmo determinista basado en el conjunto de características de los equipos de cómputo.

La clasificación determinista consistió en la asignación de una etiqueta fija (**Gama Alta**, **Gama Media** o **Gama Baja**) evaluando reglas lógicas jerárquicas sobre las especificaciones técnicas de cada laptop.

Variables de entrada utilizadas

La función toma tres características clave por cada registro (fila) del dataset:

- **CPU_Tier**: Jerarquía asignada al procesador (donde 3 representa gama alta/top, 2 gama media y 1 gama baja/entrada).
- **GPU_Dedicada**: Variable binaria (1 si cuenta con tarjeta gráfica dedicada, 0 si utiliza gráficos integrados).
- **Log2_RAM**: Transformación logarítmica base 2 de la memoria RAM ($\log_2(\text{RAM})$).
 - Un valor de 3 equivale a $2^3 = 8$ GB.
 - Un valor de 4 equivale a $2^4 = 16$ GB.

Flujo de evaluación lógica

La función evalúa los equipos en orden secuencial mediante una estructura condicional `if-elif-else`:

Paso 1: Identificación de Gama Alta ('Alta')

Se clasifica como **Gama Alta** si cumple **al menos una** de las dos condiciones siguientes:

1. Tener un procesador de nivel superior (`CPU_Tier == 3`).
2. **O** contar con gráficos dedicados (`GPU_Dedicada == 1`) junto con al menos 16 GB de RAM (`Log2_RAM >= 4`).

Si cumple cualquiera de estas dos premisas, el algoritmo le asigna **'Alta'** y no evalúa las condiciones posteriores.

Paso 2: Identificación de Gama Media ('Media')

Si el equipo no cumplió con los estándares de Gama Alta, se evalúa si cumple **ambos** criterios para ser **Gama Media**:

1. Tener un procesador de al menos nivel medio (`CPU_Tier >= 2`).
2. **Y** contar con al menos 8 GB de RAM (`Log2_RAM >= 3`).

Si cumple ambas condiciones simultáneamente, se le asigna **'Media'**.

Paso 3: Identificación de Gama Baja ('Baja')

Cualquier equipo que no haya superado los umbrales de Gama Alta ni de Gama Media (por ejemplo, laptops con 4 GB de RAM, procesadores de entrada `CPU_Tier == 1` o sin GPU dedicada) cae automáticamente en la cláusula `else` y se le asigna 'Baja'.

El resultado se guardó en la nueva columna `Gama_Tecnica`.

6.2. Modelo de Regresión (Predicción de Precio Justo)

Para auditar el costo monetario del hardware, se entrenó un modelo optimizado de **Random Forest Regressor** con ingeniería de variables y el retiro de outliers relacionados a equipos de precios elevados ($\leq \$65,000$ MXN).

La elección de usar Random Forest Regressor se fundamentó en las características de los datos con los que contamos para el proyecto.

1. Manejo de relaciones no lineales y saltos de umbral (*Thresholds*):

- El precio de una laptop no escala de forma lineal estricta. Un salto de un procesador de entrada a uno de gama alta o la inclusión de una GPU dedicada genera discontinuidad en el precio.
- Las reglas de división (*splits*) basadas en árboles capturan de forma nativa estas funciones escalonadas y no lineales sin requerir transformaciones complejas en todas las variables.

2. Robustez ante el sesgo de precios y valores atípicos (*Outliers*):

- La variable `Precio_MXN` presenta un fuerte sesgo positivo (asimetría hacia la derecha con laptops de más de \$50,000 MXN).
- Al ser un modelo basado en promedios de subárboles (ensamble por *Bagging*), Random Forest es menos sensible a valores extremos y a ruido en los precios que los algoritmos basados en optimización de distancia o mínimos cuadrados.

3. Invariancia a la escala de las variables:

- El *dataset* combina variables categóricas *one-hot* (0 ó 1), rangos ordinales de tiers (0 a 6), transformaciones logarítmicas y valores absolutos de RAM/Almacenamiento.
- Random Forest no requiere normalización ni estandarización (`StandardScaler` / `MinMaxScaler`), ya que los cortes de las ramas se evalúan sobre cada variable de forma independiente.

4. Reducción del sobreajuste (*Overfitting*) frente a un Árbol Individual:

- Un único árbol de decisión tiene alta varianza y memoriza el ruido de los datos. Random Forest promedia cientos de árboles entrenados con subconjuntos aleatorios de datos y atributos, logrando un modelo más estable que generaliza mejor en el conjunto de prueba ($R^2 = 0,70$).

El proceso de ingeniería de variables se dividió en 5 partes. .

Ingeniería de variables

Mediante expresiones regulares sobre el título (**Nombre**) y la marca del equipo, se crearon indicadores binarios (1 ó 0) para aislar atributos que afectan el valor precio:

- **Es_Reacondicionado:** Detecta palabras clave como *reacondicionado, renovado, refurbished, used, usado, open box*.
- **Es_Gaming:** Identifica líneas o términos orientados a videojuegos (*gaming, gamer, rtx, gtx, loq, victus, legion, rog, tuf, predator, katana, nitro*).
- **Es_Workstation:** Identifica equipos profesionales de estaciones de trabajo (*workstation, zbook, precision, thinkpad p, studio, probook, latitude, elite*).
- **Es_Linea_Premium:** Identifica líneas de diseño o gama alta (*zenbook, macbook pro, spectre, xps, gram, copilot+, omnibook, swift*).
- **Es_Touch y Es_OLED:** Banderas para tecnologías de pantalla táctil u OLED.
- **Es_Apple:** Variable explícita para identificar equipos Apple.

Jerarquías (Tiers de CPU y GPU)

En lugar de tratar las GPUs o CPUs como simples nombres o categorías binarias, se diseñaron funciones de estratificación técnica en rangos del 0 al 6:

- **GPU_Tier_Detallado (Escala 0 a 6):**
 - **Tier 6:** RTX 4090 / 5090 / 3090.
 - **Tier 5:** RTX 4080 / 5080 / 3080 / A3000 / A4000 / A5000.
 - **Tier 4:** RTX 4070 / 5070 / 3070 / A2000.
 - **Tier 3:** RTX 4060 / 5060 / 3060 / A1000 / A500.
 - **Tier 2:** RTX 4050 / 3050 / 2050 / 1650 / GTX / Radeon RX.
 - **Tier 1:** Gráficos integrados avanzados (Iris, Radeon, UHD).
 - **Tier 0:** Gráficos integrados básicos o no especificados.
- **CPU_Tier_Detallado (Escala 1 a 6):**
 - **Tier 6:** Intel Ultra 9 / i9 / Ryzen 9 / Apple M2 Max, M3 Max, M3 Pro, M2 Pro.
 - **Tier 5:** Intel Ultra 7 / i7 / Ryzen 7 / Apple M1, M2, M3.
 - **Tier 4:** Intel Ultra 5 / i5 / Ryzen 5.
 - **Tier 3:** Intel Core i3 / Ryzen 3.
 - **Tier 2:** Gama base / estándar.
 - **Tier 1:** Procesadores de entrada (Celeron, Pentium, N100, N150, N200, N305, Athlon).

Transformaciones Logarítmicas de los valores de memoria

Dado que la memoria RAM y el almacenamiento aumentan en potencias de 2 (4, 8, 16, 32, 512, 1024), se estabilizó su varianza mediante transformaciones en base 2:

$$\text{Log2_RAM} = \log_2(\text{RAM_GB})$$

$$\text{Log2_Almacenamiento} = \log_2(\text{Almacenamiento_GB})$$

Combianción de componentes

Para capturar los aumentos de precio que adquiere una laptop cuando combina múltiples componentes de gama alta, se crearon productos cruzados:

- **RAM_x_CPU:** $\text{RAM_GB} \times \text{CPU_Tier_Detallado}$.
- **RAM_x_GPU:** $\text{RAM_GB} \times \text{GPU_Tier_Detallado}$.
- **Gaming_x_GPU:** $\text{Es_Gaming} \times \text{GPU_Tier_Detallado}$.

Codificación Categórica y eliminación de Outliers

- **One-Hot Encoding para Fabricantes:** Se generaron columnas binarias dummies para las marcas (`Marca_...`) usando `pd.get_dummies`.
- **Filtrado de Mercado Masivo:** Se eliminaron los valores atípicos extremos acotando la muestra a laptops con precio $\leq \$65,000$ MXN.

Impacto en el Modelo

Gracias a esta ingeniería de variables mejorada, el modelo optimizado de **Random Forest Regressor** alcanzó un R^2 de **0.70 en prueba** y redujo el error medio absoluto (MAE) a **\$3,811.28 MXN**.

Métrica Financiera	Valor Obtenido
Coefficiente de Determinación (R^2 Train)	0.81
Coefficiente de Determinación (R^2 Test)	0.70
Error Absoluto Medio (MAE Test)	\$3,811.28 MXN
Raíz del Error Cuadrático Medio (RMSE)	\$5,659.87 MXN

Cuadro 3: Resultados Evaluados del Modelo de Regresión Optimizado.

Interpretación: El modelo logra explicar el **70% de la variabilidad de los precios** en el mercado real no visto. Presenta un margen de error promedio de solo **\$3,811.28 MXN** al estimar el valor comercial de una laptop basándose en la potencia de sus componentes.

7. Estrategia de Negocio

El modelo de regresión entrenado permite construir un **auditor** automatizado. Al restar el valor predicho por el modelo (*Precio Justo*) del costo real publicado en la tienda (*Precio Publicado*), la plataforma identifica discrepancias en los precios en tiempo real:

$$\text{Diferencia MXN} = \text{Precio Real Publicado} - \text{Precio Justo Modelo}$$

7.1. Identificación de Oportunidades

Ocurre cuando la diferencia es profundamente negativa (Diferencia MXN $< -\$2,000$), indicando que el comercio está vendiendo el equipo por debajo del valor de sus componentes.

Nombre del Equipo	Precio Real	Precio Justo	Descuento Real
Lenovo LOQ 16 (Ryzen 7 7840HS / 32GB / 1TB RTX4060)	\$17,999.00	\$54,759.50	-\$36,760.50
HP Workstation ZBook 17 (Core i7 / 32GB / 800GB)	\$6,499.00	\$24,443.02	-\$17,944.02
Lenovo Legion Go S Blanco (Ryzen 7 Z2 / 32GB)	\$18,500.00	\$34,665.66	-\$16,165.66
ASUS ROG Zephyrus Duo 16 (Ryzen 9 / 32GB / 3070Ti)	\$34,000.00	\$49,134.72	-\$15,134.72
HP Omen 15-ek0012la (Intel i7 / 32GB / 1TB M.2)	\$16,000.00	\$29,961.44	-\$13,961.44

Cuadro 4: Top 5 Oportunidades de Mercado Detectadas por ClaraLap.

7.2. Identificación de sobreprecios

Ocurre cuando la diferencia es positiva y elevada (Diferencia MXN $> +\$2,000$), alertando al consumidor sobre un cobro excesivo impulsado por prestigio de marca o comercialización.

Nombre del Equipo	Precio Real	Precio Justo	Sobreprecio
ASUS ROG Zephyrus 14 (Ryzen 9 / 16GB / RX 6700S)	\$54,192.00	\$27,632.96	+\$26,559.04
MacBook Pro 14" (Apple M5 Pro / 24GB / 1TB SSD)	\$56,133.00	\$32,961.50	+\$23,171.50
Laptop ASUS ExpertBook Ultra B91 (Ultra 7 / 32GB)	\$51,999.00	\$32,022.46	+\$19,976.54
Laptop HP ProBook 465 G11 (Ryzen 7 / 32GB)	\$39,179.00	\$22,754.63	+\$16,424.37
ASUS ROG Strix G16 (Ryzen 9 / 16GB / RTX 5070Ti)	\$58,999.00	\$42,692.04	+\$16,306.96

Cuadro 5: Top 5 Equipos Sobrevalorados Identificados por ClaraLap.

7.3. Motor de Match Matemático y Traductor Empático (LLM)

La plataforma opera integrando la inferencia matemática con un modelo de lenguaje en dos capas:

1. **Interpretación de Entrada (OpenAI API):** El usuario ingresa texto libre (“*Soy estudiante de arquitectura, viajo mucho, uso AutoCAD y tengo \$20,000 MXN*”). La API traduce la solicitud a parámetros estructurados JSON:

```
{
  "presupuesto_max": 20000,
  "uso_ideal": "Diseno_3D",
  "categoria_pantalla": "Ultraportatil",
  "requiere_gpu": true
}
```

2. **Motor de match:** El motor filtra el inventario activo descartando modelos no aptos, ordena las laptops restantes maximizando el ahorro estimado frente al *Precio Justo* ($R^2 = 0,70$) y selecciona el **Top 3** ajustadas a las restricciones operativas y presupuestarias del usuario.

- **Filtrado Secuencial de Hardware y Presupuesto:** Evalúa el catálogo de forma condicional, descartando equipos que superen el presupuesto límite (`presupuesto_max`) o que no cumplan con la cota inferior de memoria RAM (`ram_minima_gb`) y aceleración gráfica dedicada (`GPU_Dedicada`).
- **Mapecto Inclusivo de Gamas Técnicas:** Implementa un diccionario de inclusión hacia niveles superiores (`mapa_gamas`). Si la solicitud exige una gama técnica mínima (p. ej., *Media*), el algoritmo autoriza la selección de equipos clasificados como *Media* y *Alta*, previniendo la exclusión de oportunidades superiores dentro del presupuesto.
- **Mecanismo de Tolerancia a Fallos:** En situaciones donde la combinación de restricciones resulta en un conjunto vacío, la función evita errores de ejecución reasignando el catálogo completo ordenado de menor a mayor precio publicado.
- **Criterio de Ordenamiento y Selección Financiera:** La selección del **Top 3** se realiza ordenando el conjunto filtrado mediante la variable residual:

$$\text{Diferencia_MXN} = \text{Precio_Real_Publicado} - \text{Precio_Justo_Modelo}$$

Al ordenar de forma ascendente (valores con mayor magnitud negativa al inicio), el sistema maximiza el ahorro matemático en favor del usuario, priorizando aquellas laptops cuyo precio en tienda se encuentra más distante por debajo del valor de sus componentes.

Motor match como Evaluador de Ofertas

Esta función permite analizar la conveniencia económica de un equipo específico ingresado directamente por el usuario.

- **Delimitación del catálogo:** Filtra el catálogo general conservando únicamente las laptops que comparten características de hardware equivalentes (misma presencia de GPU dedicada y de RAM).
- **Estimación del Benchmark de Mercado:** Calcula el promedio del precio justo estimado por el modelo de Random Forest ($\bar{P}_{\text{justo}}$).
- **Clasificación Categórica por Umbrales de Tolerancia:** Evalúa la diferencia monetaria ($\Delta P = P_{\text{usuario}} - \bar{P}_{\text{justo}}$) según la siguiente matriz de

decisión:

$$\text{Veredicto} = \begin{cases} \textbf{Ganga} \text{ (}\textit{¡Excelente Oferta!}\text{)}, & \text{si } \Delta P < -\$1,000 \text{ MXN} \\ \textbf{Precio Justo} \text{ (}\textit{Precio Justo}\text{)}, & \text{si } |\Delta P| \leq \$1,000 \text{ MXN} \\ \textbf{Sobreprecio} \text{ (}\textit{Sobreprecio Detectado}\text{)}, & \text{si } \Delta P > +\$1,000 \text{ MXN} \end{cases}$$

La función retorna una estructura JSON/diccionario con la etiqueta del veredicto, el precio del usuario, el valor justo estimado y la desviación monetaria absoluta calculada en pesos mexicanos.

3. **Generación de Respuesta Empática (OpenAI API):** El LLM recibe las especificaciones técnicas del equipo ganador y redacta una justificación comercial clara y libre de jerga:

“Elegimos la Lenovo LOQ 16 porque su procesador Ryzen 7 y tarjeta RTX 4060 ejecutarán tus renders de AutoCAD sin contratiempos. Además, nuestro algoritmo detectó que este equipo tiene un valor real de hardware de \$54,759 MXN, pero actualmente cuenta con una oferta especial de \$17,999 MXN en tienda, representándote un ahorro directo de más de \$36,000 MXN.”

7.4. Conclusiones

El proyecto **ClaraLap** demuestra la viabilidad técnica y comercial de integrar técnicas de Inteligencia Artificial Clásica (Ensembles de Regresión con $R^2 = 0,70$ y MAE de \$3,811.28 MXN) con Modelos de Lenguaje Avanzados (LLMs)[. Se resuelve exitosamente la brecha entre la complejidad del hardware y las necesidades del consumidor final, proporcionando una herramienta capaz de auditar financieramente el mercado de cómputo en tiempo real y garantizando la compra de equipos disponibles con la máxima relación costo-beneficio.

7.5. Siguiendo Pasos

1. **Ampliación de Cobertura de Scraping:** Incorporar más tiendas departamentales e hipermercados en México para expandir el catálogo dinámico. Scripts en Python (BeautifulSoup, Requests, Pandas) para actualización continua de inventarios, almacenamiento local de imágenes
2. **Mapeo de Visión Computacional:** Entrenar el modelo de CNN (ResNet / VGG16) sobre el banco de imágenes descargadas para clasificar automáticamente atributos visuales del diseño físico (grosor percibido, acabados de aluminio, teclados retroiluminados) y para categorizar la estética visual del chasis (*Ultrabook, Gamer Robusta, Corporativa*)

Enlaces de Acceso al Proyecto

Recurso	Enlace de Acceso
Aplicación Web Inter-activa	https://claralap-mifrontend.vercel.app
Repositorio en GitHub	https://github.com/H-Cote/claralap

Cuadro 6: Direcciones URL oficiales de la plataforma y código fuente de ClaraLap.